

2. 중복내용

2.1 중복제거

AI학습 문서가 내용이 중복해서 존재한다면, 중복 참조가 일어나고, 정작 필요한 내용을 다른 문장은 순위에서 밀려나는 문제가 발생합니다.

사람의 이해	AI의 이해
위에 법조문 원문이 있고, 아래는 같은 말을 쉽게 풀어쓴 거구나. 둘 중 하나만 읽어도 되겠다.	두 문단이 별도 청크로 분리 의미적으로 유사항 두개문 별도 문장
잘못된 예 (Before)	올바른 예 (After)
신탁법 제22조에 의하면 "신탁재산에 대하여는 강제집행, 담보권 실행 등을 위한 경매, 보전처분 또는 국세 등 체납처분을 할 수 없다. 즉, 신탁재산은 강제집행이나 경매, 보전처분, 체납처분의 대상이 될 수 없다는 의미이다	신탁법 제22조에 의하면 "신탁재산에 대하여는 강제집행, 담보권 실행 등을 위한 경매, 보전처분 또는 국세 등 체납처분을 할 수 없다.

카테고리별 대상문서를 분리 후 되도록이면 중복된 내용을 제거합니다.

추가로 실제 업무에서 활용이 되는 내용인지 업무 담당자 확인이 필요합니다.

3. 텍스트 규칙

3.1 비정상 띄어쓰기 금지

사람의 이해	AI의 이해
"취 업 규 칙"을 보면 자동으로 "취업규칙"으로 읽는다	"취", "업", "규", "칙"을 별개 토큰으로 인식하여 "취업규칙"과 매칭에 실패한다
잘못된 예 (Before)	올바른 예 (After)
취 업 규 칙 인 사 관 리 규 정	취업규칙 인사관리규정

3.2 특수문자 사용 금지

사람의 이해	AI의 이해
동그라미 숫자 등 특수문자를 한눈에 구분한다	특수문자 인코딩이 깨지거나, 토큰나이저가 예측 불가능한 토큰으로 분리한다
잘못된 예 (Before)	올바른 예 (After)
① 근로자는... ② 사용자는... ③ 제3자는...	[1] 근로자는... [2] 사용자는... [3]제3자는...

3.3 취소선 사용 금지

사람의 이해	AI의 이해
취소선 이 그어진 텍스트는 "삭제된 내용"으로 즉시 이해한다	취소선 서식 정보가 추출 시 사라져, 삭제된 내용과 유효한 내용을 구분하지 못한다
잘못된 예 (Before)	올바른 예 (After)
연차 15 일, 20일로 변경	연차 20일

3.4 생략 표현 사용 금지: "", 상동, 좌동, 하동

사람의 이해	AI의 이해
표에서 ""나 "상동"을 보면 위 셀의 값을 가리킨다고 바로 안다	청킹 시 위 셀과 분리되면 ""가 무엇을 가리키는지 알 수 없다. 빈 값 또는 무의미한 텍스트로 처리한다
잘못된 예 (Before)	올바른 예 (After)
부서: 경영지원본부 직급: 과장 부서: "" 직급: 대리 부서: 상동 직급: 사원	부서: 경영지원본부 직급: 과장 부서: 경영지원본부 직급: 대리 부서: 경영지원본부 직급: 사원

3.5 불필요한 내용 제거

사람의 이해	AI의 이해
부칙, 신설/제정 이력 등은 맥락상 건너뛰다	부칙이나 제정 이력도 동일하게 청크로 잘라 인덱싱하므로, 검색 시 노이즈가 된다

다음 항목은 적재 전 제거

- 부칙 (시행일자만 메타데이터로 보존)
- 신설/제정/개정 이력 기록
- 문서 끝 빈 페이지, 장식용 머리글/바닥글

3.6 별지/별표 용어 통일

사람의 이해	AI의 이해
"별지"와 "별표"가 혼용되어도 맥락으로 같은 참조임을 안다	"별지 제1호"와 "별표 제1호"를 완전히 다른 문서로 인식하여 참조 관계가 끊어진다


하나의 문서 내에서 "별지" 또는 "별표" 중 하나로 통일하여 사용합니다.

4. 문서 구조 체계 (조문 계층)

4.1 계층 구조 표준

제1편

신탁의 개념



제2편

신탁법

3가지 Layer — Reasoning · Semantic · Data

레거시 테이블은 그대로 둔다. 그 위에 **Semantic Layer (meta_* 스키마)**를 두고, Reasoning Layer의 에이전트들이 그 계층을 통해 Legacy / Crawl 데이터를 조회한다.

Reasoning Layer Multi-Agent · 오케스트레이터 + 5종 MCP 서버

단일 HOST · 다중 SERVER · IN-PROCESS 호출

① Legacy (WrenAI)

② Legal-Provision

③ Legal-Relation

④ Bridge

⑤ Rules

Semantic Layer 의미 관계 · 법률 anchor · 비즈니스 규칙		POSTGRESQL · META_* SCHEMA
meta_legal_raw (+_history)	법령 원본 + 시점 이력	
meta_legal_provisions	조 / 항 / 호 구조 트리	
meta_legal_relations	법률 ↔ 법률 추론 관계 (review 워크플로)	
meta_legal_synonyms	법률 용어 / 동의어	
meta_objects	통합 노드 레지스트리 (신탁 · 법률 anchor)	
meta_links	cross-domain bridge (신탁 ↔ 법률 anchor)	
meta_knowledge	비즈니스 규칙 (신탁보수 · 자금집행 우선순위)	

Data Layer Legacy 업무 원장 · 외부 크롤러 출력 · 원본 그대로		POSTGRESQL · LEGACY / CRAWL SCHEMA
legacy.tb_trust_contract	tb_party · tb_property · 신탁 계약/당사자/부동산	
legacy.tb_project	tb_pf_loan · tb_construction · 사업/대출/시공	
crawl.crawl_runs · crawl_items	외부 크롤러 출력 (법령 · 판례 · 공시)	

온톨로지를 만들기 위해 필요한 조건

CORE PRINCIPLE
원칙

온톨로지에서 가장 인건비가 많이 드는 부분은 "관계를 정의하는 부분". 도메인 전문가가 필요하다.

